dotto_regras

October 17, 2018

1 Atividade IA - Regras de Associação

- Tarefa sobre regras de associação utilizando dataset do supermercado dotto

2 Importando as bibliotecas

In [8]:
```
import unidecode
import numpy as np
import pandas as pd
# Matplotlib for additional customization
from matplotlib import pyplot as plt
%matplotlib inline
import seaborn as sns
sns.set()
plt.rcParams['figure.figsize'] = (17,9) # Bigger figures sizes
```

3 Funções de auxilío

In [9]:
```
def norm(string):
    """Normalizes pt-br string

    Arguments:
        string {str} -- a portuguese type string (ex: não, é muito pouco...)

    Returns:
        str -- a normalized string (ex: nao, e muito pouco)
    """
    if(isinstance(string, list)):
        string = " ".join(string)

    s = unidecode.unidecode(string)
    s = s.lower().strip()
    return s
```

4 Pré-processamento de dados

- Arquivo: dotto.data
- Lendo como csv separado por espaço

In [10]:
```
# Descobrindo a maior compra
max_items = -1

with open('dotto.data', mode='r+', encoding='ISO-8859-1') as file:
    for line in file:
        line = norm(line)
        # Quebrando em lista
        length_line = len(line.split(' '))

        if length_line > max_items:
            max_items = length_line

# max_items tem a maior compra agora
print('Maior compra %d' % max_items)
```

```
Maior compra 170
```

In [11]:
```
# Lendo como um pd.DataFrame, enconding não é utf-8 por algum motivo.
data = pd.read_csv('dotto.data', delim_whitespace=True, header=None, names=range(max_
data.head(10)
```

Out[11]:

	0	1	2	3	4
0	AGUA_SANITCANDURA	CERA_BRAVO	NaN	NaN	NaN
1	ACUCAR_DA_BARRA	AGUA_SANITVAREK	ALCOOL_CANDURA	ARROZ_PRATO_FINO	AZEITE_CARBONELL
2	AGUA_SANITVAREK	CAPELETTI_MEZZANI	FILE_PEITO_FRANGO_SADIA	HARPIC_LIQATIVO	LEITE_NILZA
3	ACUCAR_UNIAO	CAFE_CABOCLO	FANTA	LEITE_MOCA	LEITE_PARMALAT
4	ADES_ORIGINAL	LEITE_PARMALAT	NaN	NaN	NaN
5	ABSINTGEL	ACHOCNESCAU	ACUCAR_UNIAO	ADES_LIGHT_MACA_ALIMLIQDE_SOJA	AGUA_SANITVAREK
6	ADES_MACA_ALIMLIQDE_SOJA	ADES_PESSEGO	AGUA_PRATA	AMACCOMFORT	BISCNESTLE
7	DESBA_BANHO	SHALL_CLEAR	NaN	NaN	NaN
8	AGUA_DE_COCO_SOCOCO	BALAS_RECHMEL_DORI	CHOCNESTLE	CORN_FLAKES_KELLOG_S	LEITE_NILZA
9	ADES_MACA_ALIMLIQDE_SOJA	BALA_CHITA	BISNAGUINHA_PULLMAN		

```
9           CREME_DE_LEITE_NESTLE         DETERGYPE

                            5                       6                    7    \
0                             NaN                     NaN                  NaN
1                BISCSAO_CARLOS             BOMBOM_LACTA  CAFE_SERRA_DA_GRAMA
2                LEITE_PARMALAT                MARGBECEL    PAPEL_HIGPERSONAL
3               MANTEIGA_BATAVO                REQNILZA               SPRITE
4                             NaN                     NaN                  NaN
5  AJAX_BOUQUET_FLORES_DO_SOL  ALFACE_MIMOSA_BIO_TERRA         ALHO_DA_ROCA
6            BISNAGUINHA_PANCO                BROCOLIS              CARRETO
7                             NaN                     NaN                  NaN
8                  MARGDORIANA                     NaN                  NaN
9      FILE_PEITO_FRANGO_SADIA         FOSFORO_FIAT_LUX           LEITE_MOCA

                     8                    9   ...   160  161  162  163  164  \
0                    NaN                  NaN ...   NaN  NaN  NaN  NaN  NaN
1             CALDO_KNORR          CHEIRO_VERDE ...   NaN  NaN  NaN  NaN  NaN
2  PIMENTA_COMARI_CEPERA                  NaN ...   NaN  NaN  NaN  NaN  NaN
3             ZIPLOC_POTE                  NaN ...   NaN  NaN  NaN  NaN  NaN
4                    NaN                  NaN ...   NaN  NaN  NaN  NaN  NaN
5             AMACCANDURA       ARROZ_ALBARUSKA ...   NaN  NaN  NaN  NaN  NaN
6            DETERGLIMPOL  FILTRO_PAPEL_MELITTA ...   NaN  NaN  NaN  NaN  NaN
7                    NaN                  NaN ...   NaN  NaN  NaN  NaN  NaN
8                    NaN                  NaN ...   NaN  NaN  NaN  NaN  NaN
9      LUSTRA_MOVPOLIFLOR           MACBARILLA ...   NaN  NaN  NaN  NaN  NaN

   165  166  167  168  169
0  NaN  NaN  NaN  NaN  NaN
1  NaN  NaN  NaN  NaN  NaN
2  NaN  NaN  NaN  NaN  NaN
3  NaN  NaN  NaN  NaN  NaN
4  NaN  NaN  NaN  NaN  NaN
5  NaN  NaN  NaN  NaN  NaN
6  NaN  NaN  NaN  NaN  NaN
7  NaN  NaN  NaN  NaN  NaN
8  NaN  NaN  NaN  NaN  NaN
9  NaN  NaN  NaN  NaN  NaN

[10 rows x 170 columns]
```

In [12]:
```
# Vizualizando a distribuição dos produtos
# Transformando em ocorrências
ocorrencias = data.stack().value_counts().reset_index()
# Plotando os 10 mais comprados
top10_plot = sns.barplot(x=ocorrencias.head(10)[0], y=ocorrencias.head(10)['index'])
top10_plot.set(xlabel='Quantidade', ylabel='Produto', title='Top 10')
plt.yticks(rotation=35)
plt.show()
```

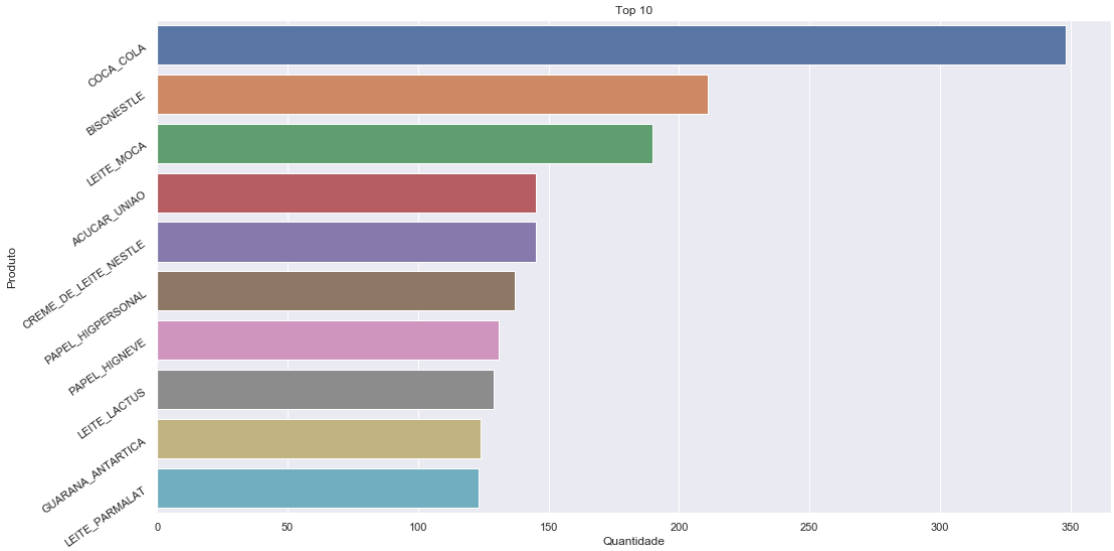

5 Modelo Apriori

5.1 Valores minimos para suporte, confiança e lift.

Considerando que o periodo da coleta dos dados seja de uma semana.

5.1.1 Suporte

O suporte indica a frequência com que um itemset ou com que A e B ocorrem juntos no conjunto de dados * Pegaremos os produtos que são vendidos pelo menos 4 vezes no dia. * Então durante uma semana ele sera vendido 47 *vezes*. Logo o suporte minimo será (4*7)/Total(1716) = 0.017

5.1.2 Confiança

A confiança de uma regra A => B é a probabilidade condicional da transação conter o conjunto de itens B, dado que contém o conjunto A. * Valores altos de confiança geram regras óbvias. * Valores baixos podem gerar regras erradas para aquele tipo de modelo de negócios. * Como 1716 ainda não é muito usaremos uma confiança não muito alta nem tão baixa entre 0.3 e 0.4.

5.1.3 Lift

A medida Lift, também conhecida por Interest, é uma das mais utilizadas para avaliar dependências entre itemsets. Leva em consideração o peso da popularidade de B também. * lift(A => B) = 1: A e B são independentes * lift(A => B) > 1: A e B são positivamente dependentes * lift(A => B) < 1: A e B são negativamente dependentes * Intervalo: [0, [* Simétrica. * Quanto maior o valor de Lift, mais interessante a regra. * O valor de minimo de lift será 3 por razões de teste em outras situações.

In [25]:
```
# apyori biblioteca simples do apriory
from apyori import apriori
transacoes = data.fillna('NaN').values
# Transacoes
regras = apriori(transacoes, min_support = 0.017, min_confidence = 0.45, min_lift = 3
# Ordenando por lift
regras = sorted(regras, key = lambda x: int(x[2][0][3]), reverse=True)

top5_regras = regras[0:5]
```

6 Analisando as regras obtidas

In [27]:
```
import networkx as nx

options = {
    'node_color': 'white',
    'node_size': 5000,
    'width': 4,
    'arrowstyle': '-|>',
    'arrowsize': 50,
    'fontsize': 16
}

g = nx.DiGraph(directed=True)

nodes = []
for item in top5_regras:
    # Primeiro indice da primeira lista interna
    # Contem o item base e o segundo item
    pair = item[0]
    items = [x for x in pair]
    nodes.append(items[0])
    nodes.append(items[1])

    g.add_nodes_from(nodes)
    g.add_edge(items[0],items[1])

    print("Regra: " + items[0] + " -> " + items[1])

    # Segundo indice é o suporte
    print("Support: " + str(item[1]))

    print("Confiança: " + str(item[2][0][2]))
    print("Lift: " + str(item[2][0][3]))
    print("====================================")

pos = nx.circular_layout(g)
```

```
        nx.draw_networkx(g, pos,**options)
        plt.show()
```

```
Regra: BOMBRIL -> CREME_DE_LEITE_NESTLE
Support: 0.017482517482517484
Confiança: 0.9375000000000001
Lift: 8.467105263157896
====================================
Regra: LEITE_MOCA -> ACHOCNESCAU
Support: 0.019813519813519812
Confiança: 0.7906976744186045
Lift: 7.141248470012239
====================================
Regra: CREME_DE_LEITE_NESTLE -> LEITE_MOCA
Support: 0.023892773892773892
Confiança: 0.7884615384615384
Lift: 7.121052631578947
====================================
Regra: FARTRIGO_RENATA -> CREME_DE_LEITE_NESTLE
Support: 0.019813519813519812
Confiança: 0.8499999999999999
Lift: 7.676842105263157
====================================
Regra: CREME_DE_LEITE_NESTLE -> PAPEL_HIGPERSONAL
Support: 0.017482517482517484
Confiança: 0.7894736842105264
Lift: 7.130193905817176
====================================
```

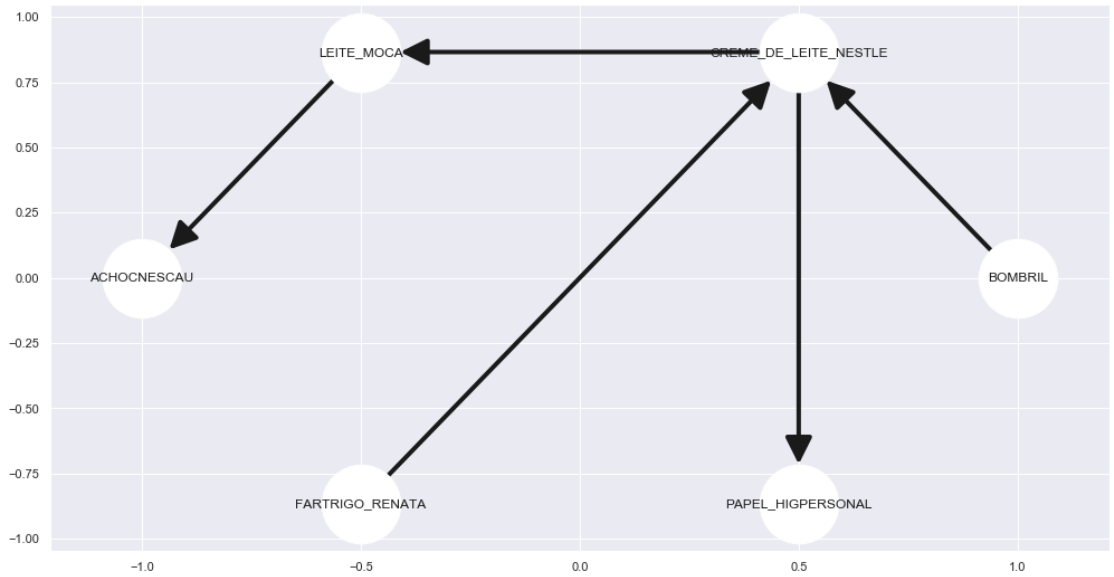

7 Conclusão

- Nota-se que algumas regras são realmente validas e até óbvias como LEITE_MOCA + ACHNESCAU = Brigadeiro e outras parecem ser totalmente estranhas BOMBRIL + CREME_DE_LEITE_NESTLE